



**Instituto Politécnico Nacional  
Unidad Profesional Interdisciplinaria de  
Ingeniería Campus Zacatecas**

**Área de ubicación para el desarrollo del trabajo**  
Ingeniería en Sistemas Computacionales.

**Línea de investigación**  
Inteligencia Artificial.

**Título del proyecto de Trabajo Terminal**  
Aplicación web para la clasificación de cáncer de  
mama usando Deep Learning.

**Presenta(n):**

Lucia Iveth De La Vega Hernández.  
Fernando Ruiz Correa.  
Jorge Ulises Zapata Arteaga.

**Director:**

Mayra Alejandra Torres Hernández.

**Asesor:**

Sergio Valadez Godínez.



Zacatecas, Zacatecas a 02 de Julio de 2025

# Índices.

## Índice de contenido.

Definición del problema.....	2
Contexto y antecedentes generales del problema.....	2
Situación problemática o problema de investigación.....	3
Estado del arte. ....	4
Descripción del proyecto.....	8
Objetivo general del proyecto. ....	9
Objetivos particulares del proyecto.....	9
Justificación.....	9
Marco teórico. ....	11
Factibilidad del proyecto.....	16
Recursos humanos.....	18
Equipo e instalaciones necesarias. ....	19
Costo estimado y financiamiento. ....	19
Bibliografía.....	21
Firmas.....	23
Autorización. ....	23
Curriculum Vitae del director y los asesores del proyecto de TT.....	24

## Índice de tablas.

Tabla 1. Comparativa de modelos utilizados por diferentes autores .....	7
Tabla 2 Comparación de características esenciales de cada modelo .....	8
Tabla 3. Recursos Humanos .....	18
Tabla 4. Equipo e instalaciones necesarias .....	19
Tabla 5. Costo estimado y financiero de equipo de cómputo .....	19
Tabla 6. Costo estimado y financiero de recursos humanos .....	20

## Índice de figuras.

Fig 1. Conversión de un clasificador de parches en un clasificador de imágenes completas entrenable de extremo a extremo mediante un diseño convoluciona [14]. .....	6
Fig 2. Diagrama de flujo de la preparación del CBIS-DDSM [8]. .....	11
Fig 3. Vista medio-lateral oblicua (MLO). .....	12
Fig 4. Vista Cráneo Caudal (CC). .....	12
Fig 5. Comparación de neurona biológica y una neurona artificial. ....	14
Fig 6. Arquitectura de redes neuronales convolucionales. ....	16
Fig 7. Conjunto de ejemplo de sistemas CADe [8]. .....	16
Fig 8. Conjunto de ejemplo de sistemas CADx [8]. .....	17

## Resumen.

El cáncer de mama es una de las principales causas de mortalidad en mujeres a nivel mundial, y su detección temprana es clave para mejorar la tasa de supervivencia. Actualmente, los métodos convencionales dependen del análisis visual de radiólogos, lo que puede generar falsos positivos y negativos, retrasando el diagnóstico y tratamiento adecuado. Este proyecto propone el desarrollo de una aplicación web que emplea técnicas de *Deep Learning* mediante redes neuronales convolucionales (CNN) para la clasificación automática de imágenes mamográficas. La aplicación procesará imágenes de rayos X, identificando patrones y anomalías asociadas a la presencia de cáncer de mama, reduciendo la carga de trabajo de los especialistas y mejorando la precisión diagnóstica. A diferencia de los sistemas actuales, este modelo utilizará una arquitectura multimodal capaz de analizar múltiples vistas de la mamografía, explotando correlaciones bilaterales para mejorar la detección de lesiones. La aplicación integrará un sistema de preprocesamiento de imágenes, entrenamiento de modelos de *Deep Learning*, análisis estadístico de resultados y una interfaz web para facilitar su uso. Se espera que esta herramienta sea parte del proceso de diagnóstico asistido por computadora, reduciendo errores en la clasificación, disminuyendo la necesidad de procedimientos invasivos innecesarios y dando un panorama más amplio para la toma de decisiones en el ámbito clínico. Con ello, se busca contribuir a la detección temprana del cáncer de mama.

**Palabras clave:** *Deep Learning, redes neuronales convolucionales, cáncer de mama, mamografía, inteligencia artificial, rayos X.*

## **Definición del problema.**

### **Contexto y antecedentes generales del problema.**

El cáncer de mama sigue siendo uno de los problemas de salud más importantes a nivel mundial, ya que representa uno de cada cuatro casos de cáncer y una de cada seis muertes por cáncer entre las mujeres de todo el mundo. Con un estimado de 2.3 millones de nuevos casos diagnosticados en 2022, se sitúa como la segunda causa principal de incidencia mundial de cáncer y representa el 11.6% de todos los casos de cáncer. La distribución geográfica del cáncer de mama revela tasas de incidencia cuatro veces más altas en regiones como América del Norte y Europa del Norte en comparación con Asia Central y Meridional y África Central [1].

Si bien los números sobre la incidencia y mortalidad del cáncer de mama son alarmantes, es importante entender las disparidades geográficas y socioeconómicas que afectan la detección y tratamiento de esta enfermedad. Esto se debe en gran medida a las diferencias en las capacidades de detección temprana y la infraestructura sanitaria. En respuesta a estos desafíos, la OMS estableció la iniciativa mundial contra el cáncer de mama en 2021, cuyo objetivo es reducir anualmente las tasas de mortalidad en un 2.5% mediante tres pilares fundamentales: promoción de la salud y detección temprana, diagnóstico oportuno y tratamiento integral del cáncer de mama [1].

El proceso de detección manual de cáncer de mama implica que un par de radiólogos interpreten las imágenes mamográficas de manera independiente, lo cual, genera costos, carga de trabajo y tiempo adicionales en los hospitales y centros de salud [2]. La detección del cáncer de mama mediante mamografías es un proceso crítico avalado por las principales agencias de salud médicas y gubernamentales debido a su eficacia para reducir la mortalidad por cáncer de mama [3]. La mamografía se considera el mejor método de diagnóstico por imágenes para la detección del cáncer de mama e implica tomar cuatro imágenes de rayos X: dos vistas para cada mama, conocidas como vista craneocaudal (CC) y oblicua mediolateral (MLO) [4]. Los radiólogos buscan anomalías como masas, calcificaciones, distorsiones arquitecturales y asimetrías [5].

Como alternativa al proceso manual, comienzan a emerger métodos y tecnologías de detección innovadoras para abordar esta situación sanitaria de manera eficaz, y mejorar la tasa de supervivencia. El objetivo del desarrollo de sistemas de detección (CAdE) y diagnóstico (CAdx) asistidos por computadora es ayudar a los radiólogos en la interpretación de imágenes mamográficas. Estos sistemas se han convertido en parte fundamental de la detección de esta enfermedad, ya que la detección temprana es un concepto clave para aumentar las probabilidades de tratamientos exitosos y mejorar la tasa de supervivencia. Las herramientas asistidas por computadora incluyen pasos importantes como el pre-procesamiento de las imágenes mamográficas, la segmentación y extracción de características del tumor, y finalmente la clasificación del caso [6].

## **Situación problemática o problema de investigación.**

Los sistemas de detección (CAdE) y de diagnóstico (CAdx) a pesar de ser un apoyo para los radiólogos únicamente son capaces de procesar sólo una vista de cada mama, ya sea la vista CC o la MLO, complicando el tener un diagnóstico correcto al analizar las radiografías. Por lo tanto, el uso de estos métodos resulta en una tasa alta de falsos positivos que pueden llevar a procedimientos invasivos innecesarios y a problemas de salud mental en los pacientes, y una tasa alta de falsos negativos que pueden retrasar el diagnóstico y tratamiento adecuado, con consecuencias potencialmente fatales [2].

Una solución a estos desafíos es desarrollar modelos multimodales, con el objetivo de fusionar las diferentes vistas de una mamografía, y así obtener un panorama más completo del caso. Estos modelos pueden aprovechar la naturaleza multivista de la mamografía, explotando asimetrías bilaterales y múltiples vistas de lesiones para lograr un análisis completo de ambas vistas en la mamografía. También ayudan a la detección de focos de cáncer mediante el uso de mapas de atención para verificar la exactitud del algoritmo e indicar áreas de interés. Además, los modelos multimodales pueden capturar y explotar correlaciones entre vistas, superando las métricas de evaluación de los sistemas de diagnóstico asistidos por computadora y brindando un mejor valor al diagnóstico [7].

## Estado del arte.

Para comenzar, es importante tener en cuenta que hay ciertas limitaciones en conjuntos de datos públicos no curados que podemos encontrar dentro de la comunidad de mamografía; ejemplos claros de este tipo de conjuntos de datos son: Base de Datos Digital para Mamografía de Detección (DDSM), la base de datos de la Sociedad de Análisis de Imágenes Mamográficas (MIAS) y el proyecto Image Retrieval in Medical Applications (IRMA) que, si bien, han sido útiles, con el paso del tiempo se han ido deteriorando en cuestión de tamaño y accesibilidad ya que, están comprimidas en formatos no estándar que requieren código de descompresión obsoleto para su uso en computadoras modernas. Como consecuencia a este hecho, muchos investigadores deben desarrollar algoritmos de segmentación para extraer características con mayor exactitud ya que las anotaciones de regiones de interés (ROI) en el DDSM solo indican la posición general de las lesiones, sin proporcionar una segmentación precisa [8].

Por otro lado, como menciona H. Chougrad et.al [9], el aprendizaje profundo suele requerir grandes conjuntos de datos para entrenar redes de cierta profundidad desde cero, sin embargo, como se menciona en su trabajo, se hizo uso de un sistema de diagnóstico asistido por computadora (CAD) para la clasificación de lesiones masivas en mamografías, utilizando un proceso de aprendizaje integral basado en redes neuronales convolucionales profundas (CNN), aplicando tres de los modelos de CNN más impresionantes propuestos recientemente: VGG16, ResNet50 e Inception v3 [10], [11], [12], entrenados en ImageNet [13], usando como principal estrategia el aprendizaje por transferencia, la cual utiliza pesos preentrenados en lugar de inicialización aleatoria ya que otorga mejores resultados, con la facilidad de que no requiere un gran volumen de datos donde, en este caso, son imágenes médicas recopiladas directamente de bases de datos públicas; siendo DDSM, INbreast, BCDR y MIAS las principales. Obteniendo así, resultados prometedores haciendo uso del modelo en cada conjunto de datos por separado. Sin embargo, realizando ajustes adicionales como preprocesamiento y normalización de regiones de interés en las mamografías y fusión de los conjuntos de datos DDSM, INbreast y BCDR se creó un conjunto de datos completo llamado “*Merged Dataset*”, el cual se utilizó para mejorar el modelo CNN InceptionV3, aumentando así la precisión de este, siendo el modelo que otorgó mejores resultados.

En contraste, tal como encontramos en trabajos como el de Shen et.al [14], se muestra que se utilizó un algoritmo asistido por computadora (CAD) que se basa en un enfoque de entrenamiento de “extremo a extremo”, donde se aprovechan todos los datos de entrenamiento con anotaciones clínicas o solo el estado del cáncer (etiquetas) de toda la imagen. Utilizando dos diferentes conjuntos de pruebas independientes: De mamografías de película digitalizada de la Base de Datos Digital para Mamografías de Detección (CBIS-DDSM41), que constaba de 2478 imágenes de mamografía de 1249 mujeres imágenes de mamografía con vistas craneocaudales (CC) y oblicuas medio laterales (MLO) con anotaciones a nivel pixel de los ROI y sus etiquetas patológicamente confirmadas benignas o malignas; y De Mamografía Digital de Campo Completo (FFDM), desarrollando un clasificador de imágenes entrenado de extremo a extremo mediante un diseño convolucional profundo, encontrando así que, cuando se utiliza el clasificador en mamografías digitalizadas (CBIS-DDSM), dicho clasificador puede transferirse con éxito a imágenes FFDM utilizando un subconjunto de datos para ajuste fino, sin necesidad de depender nuevamente de anotaciones de lesiones, con esto se demostrando la eficacia del modelo para adaptarse a diferentes plataformas de mamografía.

Como se mencionó anteriormente, uno de los métodos utilizados en el trabajo de Shen et. al [14], fue la “Conversión de un clasificador de reconocimiento de parches a imágenes completas” mostrado en Fig.1. Para realizar la clasificación o segmentación en imágenes complejas de gran tamaño, una estrategia común implica el uso de un clasificador de dos pasos en la ventana deslizante para reconocer parches locales en una imagen y generar una cuadrícula de salidas probabilísticas y por consiguiente, otro proceso para resumir las salidas del clasificador de parches para dar el resultado final de la clasificación o segmentación. Teniendo como principal problema que, cada uno de estos pasos debe ser optimizado por separado; sin embargo, Shen et.al [14] lograron juntar estos dos pasos dando como resultado una categorización de 5 posibles clases para cada imagen: Clasificación benigna, clasificación maligna, masa benigna, masa maligna y fondo. Además, haciendo uso de redes neuronales convolucionales profundas (CNN) como ResNet50 y VGG16 con dos posibles variantes: preentrenado (Y) o no preentrenado (N, inicializado aleatoriamente) y dos conjuntos de pruebas (S1 y S10), les otorgó como resultado que, el modelo Resnet50 preentrenado



utilizando el conjunto de pruebas S1 fue el de mayor impacto, mostrando los resultados más prometedores.




Fig 1. Conversión de un clasificador de parches en un clasificador de imágenes completas entrenable de extremo a extremo mediante un diseño convolucional [14].

En cambio, en los trabajos de Al-masni et. al [15] se encuentran resultados sorprendentes utilizando un sistema CAD basado en redes neuronales totalmente conectadas (FC-NN) y en YOLO (You Only Look Once). Para el entrenamiento del modelo, se hizo uso de la base de datos DDSM, tomando un total de 600 imágenes para el entrenamiento.

El modelo propuesto por Al-masni et al. [15] consta de cuatro etapas principales. En la primera etapa se realiza un preprocesamiento de los mamogramas obtenidos de la base de datos DDSM [16] mediante el método de aumento, permitiendo triplicar el número de imágenes obtenidas al rotar las imágenes en  $90^\circ$ ,  $180^\circ$  y  $270^\circ$  cada una, obteniendo un total de 2400 mamogramas aumentados. Posteriormente, se implementa la técnica de ecualización periférica multiumbral [17], [18] para eliminar el efecto de la compresión mamaria. Además, para realizar la segmentación se genera la máscara que contiene la región mamaria mediante la técnica de umbralización de Otsu. A continuación, la imagen de máscara se multiplica por una versión borrosa de la original que se produce aplicando un filtro de paso bajo gaussiano 2D, permitiendo eliminar el fondo y los datos irrelevantes.

En la segunda etapa se divide el mamograma en segmentos de  $N \times N$ , para ser evaluado por YOLO. Posteriormente el algoritmo predice si el objeto que está dentro de la

celda pertenece a una clase en específico, permitiendo la identificación de posibles regiones sospechosas.

En la tercera etapa se eliminan las celdas duplicadas y se seleccionan los cuadros con mayor porcentaje de confianza hasta que se hayan eliminado todos los cuadros redundantes.

Finalmente se clasifica el mamograma completo, para determinar si la imagen corresponde a un caso de cáncer de mama maligno o benigno.

Autor	Modelo	Database	No. De Imágenes	Accuracy (%)
H. Chougrad et.al [9]	VGG16; ResNet50; <b>Inception V3</b>	DDSM; BCDR; INbreast; MD	5316; 600; 20; 6116	97.12%, 97.27%, <b>97.35%</b> ; 96.50%, 96.50%, <b>96.67%</b> ; 95.00%, 92.50%, <b>95.50%</b> ; 98.64%, 98.77%, <b>98.98%</b>
Shen et.al [14]	<b>Resnet50</b> (Y, N), VGG16 (Y)	CBIS-DDSM41	2478	Resnet50 N (S1) 97% <b>Resnet50 Y(S1) 99%</b> Resnet50 N(S10) 63% Resnet50 Y(S10) 89% Resnet50 Y(S1g) 76% VGG16 Y(S10) 84%
Al-masni et al [15]	YOLO-based	DDSM	2400	99.70%

*Tabla 1. Comparativa de modelos utilizados por diferentes autores.*

En la Tabla 1 se muestra una comparación de los distintos modelos CNN utilizados por diferentes autores mostrando su precisión en la detección del cáncer de mama, la base de datos utilizada y el número de imágenes con las que cuenta. De esta manera se concluye que el modelo YOLO-based es el que muestra los mejores resultados dando una mayor precisión.

<b>Autor</b>	<b>Database</b>	<b>No. De Imágenes</b>	<b>Software de Visualización de Resultados</b>	<b>Vistas de mamografía</b>	<b>Entrenamiento del modelo</b>	<b>Costo</b>
H. Chougrad et.al [9]	DDSM; BCDR; INbreast; MD	5316; 600; 20; 6116	Software de diseño asistido por computadora (CAD)	Craneocaudal (CC) y Medio Lateral Oblicua (MLO)	Deep Learning	No se menciona
Shen et.al [14]	CBIS-DDSM41	2478	Software de diseño asistido por computadora (CAD)	Craneocaudal (CC) y Medio Lateral Oblicua (MLO)	Deep Learning	No se menciona
Al-masni et al [15]	DDSM	2400	Software de diseño asistido por computadora (CAD)	Craneocaudal (CC) y Medio Lateral Oblicua (MLO)	Deep Learning	No se menciona
L. De La Vega et.al	CBIS-DDSM	2620	Aplicación Web	Craneocaudal (CC) y Medio Lateral Oblicua (MLO)	Deep Learning	Sin costo

*Tabla 2. Comparación de características esenciales de cada modelo.*

En la Tabla 2 se muestran las características más esenciales de cada uno de los modelos mencionados, comparando los tres modelos estudiados con el cuarto que es el modelo propuesto a desarrollar.

## **Descripción del proyecto.**

El presente proyecto consiste en el diseño e implementación de una aplicación web que emplea técnicas de Deep Learning utilizando redes neuronales convolucionales para la clasificación de posibles casos de cáncer de mama. Dicha aplicación procesará imágenes mamográficas con el objetivo de identificar patrones, anomalías u otro tipo de indicio asociados a la presencia de cáncer. Proporcionando los resultados en la interfaz web de la aplicación.

## **Objetivo general del proyecto.**

Clasificar posibles casos de cáncer de mama utilizando técnicas de Deep Learning, desarrollando modelos multimodales, integrando diferentes perspectivas de una mamografía mediante el uso de una aplicación web.

## **Objetivos particulares del proyecto.**

- Optimizar la calidad de las imágenes de rayos X mediante el pre-procesamiento de imágenes para aumentar la exactitud de la clasificación de las mamografías.
- Clasificar imágenes de rayos X mamarios usando técnicas de Deep Learning, con el fin de apoyar la detección temprana de posibles casos de cáncer de mama, mediante la implementación de una aplicación web.
- Entrenar redes neuronales convolucionales para la clasificación de casos de cáncer de mama.
- Analizar estadísticamente de los resultados de las redes neuronales convolucionales para evaluar el rendimiento del modelo.
- Visualizar los resultados de la clasificación para facilitar su interpretación por parte del personal medico mediante el desarrollo de una aplicación web.

## **Justificación.**

El cáncer de mama es una de las principales causas de mortalidad en mujeres a nivel mundial, representando un alto porcentaje de los nuevos casos de cáncer diagnosticados anualmente. La detección temprana es clave para mejorar las tasas de supervivencia, pero los métodos convencionales presentan limitaciones importantes, como la dependencia del análisis visual por radiólogos y la alta tasa de falsos positivos y negativos [1].

Actualmente, los sistemas de detección asistida por computadora (CAdE) y diagnóstico asistido por computadora (CAdx) han demostrado ser herramientas útiles en la interpretación de mamografías, pero presentan deficiencias como el procesamiento limitado de vistas de la mamografía (CC o MLO por separado) y la incapacidad de explotar correlaciones entre múltiples vistas. Esto puede llevar a diagnósticos incorrectos y tratamientos innecesarios [8].

En este proyecto propone el desarrollo de una aplicación web basada en Deep Learning que implementa redes neuronales convolucionales (CNN) para mejorar la clasificación de cáncer de mama. A diferencia de los métodos tradicionales, nuestra propuesta busca integrar un modelo multimodal capaz de analizar múltiples vistas de la mamografía, permitiendo una detección más precisa de anomalías.

## Marco teórico.

El CBIS-DDSM (Conjunto de Imágenes de Mama Curado del DDSM) es una versión actualizada del DDSM que ofrece datos de fácil acceso y una segmentación mejorada de las regiones de interés (ROI). Incluye imágenes descomprimidas, selección y curación de datos por mamógrafos capacitados, segmentación actualizada de masas y cuadros delimitadores, así como diagnóstico patológico para los datos de entrenamiento, formateados de manera similar a los conjuntos de datos modernos de visión por computadora. El conjunto de datos contiene 753 casos de calcificaciones y 891 casos de masas, proporcionando un tamaño de datos adecuado para el análisis de sistemas de apoyo a la decisión en mamografía [8].





Fig 2. Diagrama de flujo de la preparación del CBIS-DDSM [8].

En Fig. 2 se muestra el proceso de la preparación de las imágenes de la base de datos DDSM curadas para la utilización del dataset CBIS-DDSM.


El DDSM (Base de Datos Digital para el Cribado de Mamografía) es una base de datos con 2,620 estudios de mamografía en película escaneada, que incluyen casos normales, benignos y malignos con información patológica verificada. La base de datos se lanzó en 1997 en la cual las imágenes del DDSM se almacenan en archivos comprimidos con un formato no estándar; además las anotaciones de las regiones de interés (ROI) para las anomalías en el DDSM indican la posición general de las lesiones [8].

Un examen mamográfico de detección consiste en cuatro imágenes de dos vistas diferentes: La vista oblicua mediolateral (MLO), la cual es una proyección tomada en un ángulo de 45° y muestra una parte del músculo pectoral, que permite evaluar el tejido mamario y localizar lesiones en cuadrantes superiores e inferiores de la mama. Mientras que la otra vista, la vista cráneo caudal (CC), recoge la mayor parte de la mama en una vista de arriba hacia abajo, permitiendo la localización de lesiones en los cuadrantes interno (inferior en la placa) y externo (superior en la placa) de la mama [19].



*Fig 3. Vista medio-lateral oblicua (MLO).*

En Fig. 3 se muestra la vista medio-lateral oblicua, en la cual se aprecia la parte alta de la axila hasta la zona por debajo del pliegue inframamario [20].



*Fig 4. Vista Cráneo Caudal (CC).*

En Fig. 4 se muestra la vista cráneo caudal donde se puede observar con una mayor precisión el tejido medial [20].

Como menciona Molano Gómez [21], las regiones de interés (ROI) corresponden a un conjunto de píxeles dentro de una imagen que destacan por su relevancia en un análisis o estudio específico. En el ámbito médico, su identificación es clave para el diagnóstico de enfermedades y el desarrollo de investigaciones, ya que contienen información crucial sobre diversas condiciones.

Una de las técnicas más empleadas para detectar ROI es la segmentación, la cual puede realizarse de forma automática o semiautomática. Este proceso permite delimitar y diferenciar áreas de interés dentro de una imagen médica mediante el análisis de características como la intensidad de los píxeles, la textura, la forma y la ubicación espacial de las estructuras. Una vez identificada la ROI, es posible extraer datos cuantitativos o cualitativos, como tamaño, densidad o textura, para su posterior análisis. Además, como señala Molano Gómez, las ROI tienen diversas aplicaciones en la medicina, siendo fundamentales en la detección de tumores como el cáncer de mama, de pulmón y de colon, entre otros [21].

Por su parte, se hace uso de Deep Learning, el cual, es una técnica de aprendizaje que permite a los modelos computacionales aprender múltiples niveles de abstracción mediante capas, permitiendo realizar tareas más complejas que el Machine Learning, como clasificar patrones dentro de una imagen para detectar lesiones en la mama [22]. El Deep Learning se caracteriza por tener un modelo de capas, estas capas son alimentadas con una gran cantidad de datos para aprender de manera independiente, permitiendo descifrar patrones muy complejos para generar una jerarquía de características que van desde un nivel de abstracción bajo hasta uno más alto [21].

El Deep Learning se diferencia de los algoritmos de aprendizaje poco profundos por la cantidad de transformaciones que se aplica a la señal de entrada a medida que se va propagando por las diferentes capas, hasta llegar a la capa de salida. Para que sea considerado aprendizaje profundo, es necesario que contenga al menos 2 capas intermedias.

La base para la creación de modelos con múltiples capas, son las redes neuronales, las cuales reciben su nombre en base a las redes neuronales biológicas. Estas redes neuronales artificiales, se encuentran interconectadas y transmiten información y señales para aprender.



Cada red neuronal está compuesta por unidades de procesamiento que las conectan con las otras redes neuronales, estas unidades son llamados nodo, creados con el objetivo de conectar cada red y aprender de la experiencia [21].




Fig 5. Comparación de neurona biológica y una neurona artificial.

En Fig. 5 se hace una comparación de una neurona biológica y de una neurona artificial, como se puede apreciar, la neurona artificial toma como base una neurona biológica para su funcionamiento.

Una red neuronal se basa en tres tipos de capas:

- Capa de entrada: Es la capa la cual recibe los datos de entrada.
- Capa oculta: Esta capa puede estar compuesta por una o más capas de neuronas con cantidades distintas de neuronas. Esta capa se encarga de realizar el procesamiento de datos, extrayendo características y patrones para realizar predicciones.
- Capa de salida: Esta capa se encarga de enviar las predicciones realizadas en las capas anteriores [21].

Ahora bien, una vez definidos los conceptos primordiales en la identificación y procesamiento de imágenes, es necesario hablar del criterio principal en este ámbito. De acuerdo con Molano Gómez [21], las redes neuronales convencionales, son redes totalmente

interconectadas, es decir, cada neurona en una capa oculta está vinculada con todas las neuronas de la capa subsiguiente y precedente. En el Deep Learning y procesamiento de imágenes, una imagen se interpreta como una matriz de píxeles, por lo que cada píxel de la imagen de entrada estaría vinculado a cada neurona de la primera capa oculta de la red, el principal problema con esto es que el número de conexiones es excesivo, por lo que redes completamente conectadas se vuelve un camino inviable incluso en imágenes relativamente pequeñas.

Para resolver esta problemática, se crearon las redes neuronales convolucionales, las cuales son una variante de las redes convencionales que emulan el córtex visual del cerebro humano para identificar diferentes características en las entradas, lo que a última instancia permite “ver” o identificar objetos. El principal beneficio es que cada segmento de la red se entrena para llevar a cabo una tarea específica, aprendiendo de diferentes niveles de abstracción, lo que reduce el número de conexiones en las capas ocultas y acelera el entrenamiento. Esto significa que las primeras capas pueden detectar características básicas como líneas, curvas o bordes y se van especializando hasta llegar a capas más profundas capaces de reconocer formas complejas como un rostro, una silueta o un objeto [21].

Como nos menciona Molano Gómez [21], la arquitectura de una red neuronal convolucional (CNN) se puede separar en dos grandes etapas, por un lado, la etapa de extracción de características que a su vez está compuesta por 40 una o más capas convolucionales en donde se realizan pasos fundamentales: convolución, activación y pooling, y por otro lado, la etapa de clasificación, también llamada capa completamente conectada (fully connected layer), que comienza con un aplanamiento y continua con una red neuronal tradicional fully connected, en donde se realizará la clasificación final; mostrando así una imagen de la arquitectura en la figura 4 [21].




Fig 6. Arquitectura de redes neuronales convolucionales.

Los sistemas CAD son útiles para la detección, segmentación y clasificación de masas mamarias, tareas que presentan desafíos debido al bajo índice de señal-ruido en la visualización de las masas, junto con la falta de patrones consistentes en cuanto a forma, tamaño, apariencia y ubicación de estas [23].

Dentro de los sistemas CAD existen dos categorías utilizadas, los sistemas de detección asistida por computadora (CADE) y diagnóstico asistido por computadora (CADx) están diseñados para ayudar a los radiólogos en la interpretación de mamografías [8].

Performance statistics of selected CADE methods for the detection of abnormalities					
Authors	Size of Data set (Cases)	Public or Private Data	Accuracy	Sensitivity	False Positives Per Image
Karssemeijer and te Brake <sup>13</sup>	50	Public (MIAS*)	NA	90%	1
Mudigonda <i>et al.</i> <sup>14</sup>	56	Public (MIAS*)	NA	81%	2.2
Liu <i>et al.</i> <sup>15</sup>	38	Public (MIAS*)	NA	90%	1
Li <i>et al.</i> <sup>16</sup>	94	Private	NA	91%	3.21
Baum <i>et al.</i> <sup>17</sup>	63	Private	NA	89%	0.61
Kim <i>et al.</i> <sup>18</sup>	83	Private	NA	96%	0.2
Yang <i>et al.</i> <sup>19</sup>	203	Private	96.1%	95–98%	1.8
The <i>et al.</i> <sup>20</sup>	123	Private	NA	94%	2.3 per case
Sadaf <i>et al.</i> <sup>21</sup>	127	Private	NA	91%	NA
Chu <i>et al.</i> <sup>22</sup>	230	Public (DDSM <sup>1</sup> )	NA	98.5%	0.84

Fig 7. Conjunto de ejemplo de sistemas CADE [8].

El CADE se emplea para detectar estructuras anómalas dentro de la mamografía [8]. En la figura 7 se muestran un conjunto de ejemplos de sistemas CADE existentes con las características propias de cada sistema del tamaño de datos, si los datos son públicos o privados, su precisión, sensibilidad y los falsos positivos de las imágenes.

Performance statistics of selected CADx methods for the classification of masses				
Authors	Size of Data set (Cases)	Public or Private Data	Classification Accuracy	Az*
Brzakovic <i>et al.</i> <sup>23</sup>	25	Private	85%	NA
Huo <i>et al.</i> <sup>24</sup>	65	Private	NA	0.94
Rangayyan <i>et al.</i> <sup>25</sup>	54	Public (MIAS <sup>†</sup> ) and Private	91%	NA
Mudigonda <i>et al.</i> <sup>26</sup>	39	Public (MIAS <sup>†</sup> )	82.1%	0.85
Sahiner <i>et al.</i> <sup>27</sup>	102	Private	NA	0.91
Timp <i>et al.</i> <sup>28</sup>	465	Private	NA	0.77
Ganesan <i>et al.</i> <sup>29</sup>	282	Private	88.8%	NA
Görgel <i>et al.</i> <sup>30</sup>	78, 65	Private, Public (MIAS <sup>†</sup> )	91.4%, 90.1%	NA
Qiu <i>et al.</i> <sup>31</sup>	560	Private	77.14%	0.81
Choi <i>et al.</i> <sup>32</sup>	600	Public (DDSM <sup>‡</sup> )	NA	0.88

*Fig 8. Conjunto de ejemplo de sistemas CADx [8].*

El CADx se utiliza para determinar la relevancia de la anomalía detectada [8]. En la figura 8 se muestran ejemplos de sistemas CADx con las características del sistema del tamaño de datos, si los datos son públicos o privados y su precisión.

## Factibilidad del proyecto.

### Recursos humanos.

Integrante	Función	Correo electrónico	Teléfono de contacto
Lucia Iveth De La Vega Hernández	Analista Desarrollador Tester	luciaiveth270804@gmail.com	492-218-22-52
Fernando Ruiz Correa	Analista Desarrollador Tester	matcorrea1708@gmail.com	492-116-60-65
Jorge Ulises Zapata Arteaga	Analista Desarrollador Tester	uliseszaar@gmail.com	492-113-48-56
Mayra Alejandra Torres Hernández	Directora	mtorresh@ipn.mx	492-103-18-58
Sergio Valadez Godínez	Asesor	svaladezg@gmail.com	477-521-21-80

*Tabla 3. Recursos Humanos.*

## Equipo e instalaciones necesarias.

Equipo / Instalaciones	Características	Software necesario
Laptop	<ul style="list-style-type: none"> <li>• 8GB de RAM</li> <li>• 128GB en SSD</li> <li>• Resolución de pantalla mínima (2560 x 1600)</li> <li>• Procesador 1.6 GHz Intel Core i5 dos núcleos</li> </ul>	<ul style="list-style-type: none"> <li>• SO macOS versión 14.2.1</li> <li>• Visual studio code</li> <li>• Anaconda (Python)</li> </ul>
Computadora de Laboratorio de Cómputo.	<ul style="list-style-type: none"> <li>• 16 GB de RAM.</li> <li>• 512 GB en SSD</li> <li>• NVIDIA RTX 3060</li> <li>• Procesador AMD Ryzen 5 de 2.5 GHz</li> </ul>	<ul style="list-style-type: none"> <li>• Windows 11.</li> <li>• Visual Studio Code.</li> <li>• Anaconda (Python)</li> </ul>

*Tabla 4. Equipo e instalaciones necesarias.*

## Costo estimado y financiamiento.

Descripción	Precio unitario	Cantidad	Financiamiento	Total
Laptop MacBook Air	MXN \$10,000.00	1	Cuenta propia	MXN \$10,000.00
Computadora de Laboratorio de Cómputo	MXN \$10,000.00	2	Financiamiento de UPIIZ	MXN \$20,000.00
Servicio de Internet	MXN \$320.00	1	Cuenta propia	MXN \$320.00
Servicio de Electricidad	MXN \$250.00	1	Cuenta propia	MXN \$250.00
<i>Total:</i>				MXN \$30,570.00

*Tabla 5. Costo estimado y financiero de equipo de cómputo.*

A lo anterior, se agrega los costos de horas de trabajos de los integrantes que conforman el equipo del proyecto:

<b>Recurso humano</b>	<b>Pago por hora</b>	<b>Horas de trabajo requeridas</b>	<b>Financiamiento</b>	<b>Total</b>
Lucia Iveth De La Vega Hernández	200.00 MXN	160	Cuenta propia	\$32,000 MXN
Fernando Ruiz Correa	200.00 MXN	160	Cuenta propia	\$32,000 MXN
Jorge Ulises Zapata Arteaga	200.00 MXN	160	Cuenta propia	\$32,000 MXN
Mayra Alejandra Torres Hernández	200.00 MXN	100	Por parte del IPN	\$20,000 MXN
Sergio Valadez Godínez	200.00 MXN	100	Por parte del IPN	\$20,000 MXN
			<i>Total mensual:</i>	\$136,000 MXN

*Tabla 6. Costo estimado y financiero de recursos humanos.*

# Bibliografía.

- [1] Sung, H., Ferlay, J., Siegel, R. L., Laversanne, M., Soerjomataram, I., Jemal, A., and Bray, F. Global cancer statistics 2020: Globocan estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: A Cancer Journal for Clinicians* 71 (5 2021), 209–249.
- [2] Moura, D. C., and López, M. A. G. An evaluation of image descriptors combined with clinical data for breast cancer diagnosis. *International Journal of Computer Assisted Radiology and Surgery* 8 (7 2013), 561–574.
- [3] Xi, P., Shu, C., and Goubran, R. Abnormality detection in mammography using deep convolutional neural networks. In *2018 IEEE International Symposium on Medical Measurements and Applications (MeMeA)* (6 2018), IEEE, pp. 1–6.
- [4] Ramos-Pollán, R., Guevara-López, M. A., Suárez-Ortega, C., Díaz-Herrero, G., Franco-Valiente, J. M., Rubio-Del-Solar, M., González-De-Posada, N., Vaz, M. A. P., Loureiro, J., and Ramos, I. Discovering mammography-based machine learning classifiers for breast cancer diagnosis. *Journal of Medical Systems* 36 (8 2012), 2259–2269.
- [5] Shen, Y., Wu, N., Phang, J., Park, J., Liu, K., Tyagi, S., Heacock, L., Kim, S. G., Moy, L., Cho, K., and Geras, K. J. An interpretable classifier for high-resolution breast cancer screening images utilizing weakly supervised localization. *Medical Image Analysis* 68 (2 2021), 101908.
- [6] Quintana, G. I., Li, Z., Vancamberg, L., Mougeot, M., Desolneux, A., and Muller, S. Exploiting patch sizes and resolutions for multi-scale deep learning in mammogram image classification. *Bioengineering* 10 (5 2023).
- [7] Lopez, E., Grassucci, E., Valleriani, M., and Comminiello, D. Multi-view hypercomplex learning for breast cancer screening. *IEEE Transactions on Pattern Analysis and Machine Intelligence* (4 2022).
- [8] R. S. Lee, F. Gimenez, A. Hoogi, K. K. Miyake, M. Gorovoy, y D. L. Rubin, «A curated mammography data set for use in computer-aided detection and diagnosis research», *Scientific Data*, vol. 4, n.º 1, Art. n.º 1, dic. 2017, doi: 10.1038/sdata.2017.177.
- [9] H. Chougrad, H. Zouaki, y O. Alheyane, «Deep Convolutional Neural Networks for breast cancer screening», *Computer Methods and Programs in Biomedicine*, vol. 157, pp. 19-30, abr. 2018, doi: 10.1016/j.cmpb.2018.01.011.
- [10] K. Simonyan, A. Zisserman, Very Deep Convolutional Networks for Large-Scale Image Recognition, *ArXiv14091556 Cs.* (2014). <http://arxiv.org/abs/1409.1556> (accessed February 10, 2017).
- [11] K. He, X. Zhang, S. Ren, J. Sun, Deep Residual Learning for Image Recognition, in: 2016: pp. 770–778. [http://www.cv-foundation.org/openaccess/content\\_cvpr\\_2016/html/He\\_Deep\\_Residual\\_Learning\\_CVPR\\_2016\\_paper.html](http://www.cv-foundation.org/openaccess/content_cvpr_2016/html/He_Deep_Residual_Learning_CVPR_2016_paper.html) (accessed February 10, 2017).
- [12] Rethinking the Inception Architecture for Computer Vision, in: 2016: pp. 2818–2826. [http://www.cv-foundation.org/openaccess/content\\_cvpr\\_2016/html/Szegedy\\_Rethinking\\_the\\_Inception\\_CVPR\\_2016\\_paper.html](http://www.cv-foundation.org/openaccess/content_cvpr_2016/html/Szegedy_Rethinking_the_Inception_CVPR_2016_paper.html) (accessed February 10, 2017).
- [13] J. Deng, W. Dong, R. Socher, L.J. Li, K. Li, L. Fei-Fei, ImageNet: A large-scale hierarchical image database, in: 2009 IEEE Conf. Comput. Vis. Pattern Recognit., 2009: pp. 248–255. doi:10.1109/CVPR.2009.5206848.



- [14] L. Shen, L. R. Margolies, J. H. Rothstein, E. Fluder, R. McBride, y W. Sieh, «Deep Learning to Improve Breast Cancer Detection on Screening Mammography», *Scientific Reports*, vol. 9, n.º 1, Art. n.º 1, ago. 2019, doi: 10.1038/s41598-019-48995-4.
- [15] M. A. Al-masni *et al.*, «Simultaneous detection and classification of breast masses in digital mammograms via a deep learning YOLO-based CAD system», *Computer Methods and Programs in Biomedicine*, vol. 157, pp. 85-94, abr. 2018, doi: 10.1016/j.cmpb.2018.01.017.
- [16] Z. Jiao, X. Gao, Y. Wang and J. Li, "A deep feature based framework for breast masses classification," *Neurocomputing*, vol. 197, no. C, pp. 221-231, 2016.
- [17] T. Wu, R. H. Moore and D. B. Kopans, "Multi-threshold peripheral equalization method and apparatus for digital mammography and breast tomosynthesis," U.S. Patent 7,764,820, 2010.
- [18] M. A. Al-antari, M. A. Al-masni and Y. M. Kadah, "Hybrid model of computer-aided breast cancer diagnosis from digital mammograms," *Journal of Scientific and Engineering*, vol. 04, no. 02, pp. 114-126, 2017.
- [19] A. J. Bekker, H. Greenspan, y J. Goldberger, «A multi-view deep learning architecture for classification of breast microcalcifications», en *2016 IEEE 13th International Symposium on Biomedical Imaging (ISBI)*, IEEE, abr. 2016, pp. 726-730. doi: [10.1109/ISBI.2016.7493369](https://doi.org/10.1109/ISBI.2016.7493369).
- [20] V. Rodríguez López, *Análisis de imágenes de mamografía para la detección de cáncer de mama*. REPOSITORIO NACIONAL CONACYT, 2012.
- [21] Molano Gómez, R., *Geometría computacional aplicada al reconocimiento de regiones de interés en visión por computador*, 1st ed. 2023.
- [22] Y. LeCun, Y. Bengio, y G. Hinton, "Deep learning," *Nature*, vol. 521, pp. 436-444, 2015. doi: 10.1038/nature14539.
- [23] N. Dhungel, G. Carneiro, y A. P. Bradley, «A deep learning approach for the analysis of masses in mammograms with minimal user intervention», *Medical Image Analysis*, vol. 37, pp. 114-128, abr. 2017, doi: 10.1016/j.media.2017.01.009.

## Firmas.



Lucia Iveth De La Vega Hernández.



Fernando Ruiz Correa.



Jorge Ulises Zapata Arteaga.


## Autorización.

Por medio del presente autorizo la impresión y distribución del presente protocolo, toda vez que lo he leído, comprendido en su totalidad, y estar de acuerdo con su desarrollo.

Atentamente;



Mayra Alejandra Torres Hernández.



Sergio Valadez Godínez.

# Curriculum Vitae del director y los asesores del proyecto de TT.



CELULAR 492-103-1858  
CORREO ELECTRÓNICO mtorresh@ipn.mx matorres\_26@yahoo.com.mx

**Mayra Alejandra Torres Hernández**

## Información personal

- Lugar de nacimiento: Zacatecas, Zac.
- Nacionalidad: Mexicana

## Educación

2020-Actualmente      Doctorado en Ingeniería y Tecnología Aplicada  
8to Semestre (95% Créditos)  
UAZ (Universidad Autónoma de Zacatecas)

### Título de proyecto de tesis:

Modelos de redes neuronales para la optimización de  
rutinas de movimiento para un brazo robótico en entornos de  
la I4.0

2004-2006      Maestría en Ciencias en Ciencias  
de la Computación

Especialidad en sistemas inteligentes  
Instituto Tecnológico de León.

### Título de proyecto de tesis:

Mejoramiento del diseño de Elementos  
Ópticos Difractivos Generados por Computadora mediante  
la aplicación de Algoritmos Genéticos.

1997 – 2002      Licenciatura  
Ingeniería en Sistemas Computacionales  
Instituto Tecnológico de Zacatecas  
Zacatecas, Zac.

## Experiencia Laboral

Ene 2009- Actual      Profesor Titular “C “ Tiempo completo de la UPIIZ-IPN

2007-2009      Docente Tiempo Completo  
Universidad Politécnica del Estado de Zacatecas (UPZ)

2002-2004      Desarrolladora de Sistemas –  
Montecristo Systems S.A. de C.V. -Aguascalientes

## Investigación y Publicaciones

- Publicación del artículo “Capacidades Dinámicas en empresas de TI en México”, Revista Politecnología: Publicación del Subsistema de Universidades Politécnicas. Num. 1, Vol. 1, diciembre 2009.

- Participación en el Proyecto de investigación “Puesta en Marca del Centro de Desarrollo de Software de la UPIIZ”  
Autorizado y Apoyado por la SIP 2014

- Participación en el Proyecto de Investigación “Desarrollo de una aplicación

Móvil para el Conteo de Colonias en cultivos microbianos” Autorizado y Apoyado por la SIP  
2016

- Publicación del artículo “Mobile Application for Automatic Counting of Bacterial Colonies”, Congreso Internacional de Mejora de Proceso de Software, CIMPS 2016, Springerlink

- Publicación del artículo: Performance Analysis of Embedded Multilayer Perceptron Artificial Neural Networks on Smart Cyber-Physical Systems for IoT Environments by Sensors MDPI, 04 Agosto 2023.

- Publicación del artículo ” Sistema web RoadMap para la administración de proyectos en la norma ISO/IEC 29110” Congreso Internacional de Mejora de Proceso de Software, CIMPS 2023, IEEE Xplore

- Publicación del artículo ”Plataforma de apoyo a la investigación de redes neuronales para resolver la cinemática inversa de un Brazo Robótico de 3DoF” 4º Congreso International de Investigación Academia Journals CDMX 2024 coorganizado con el Instituto Tecnológico de Iztapalapa y Centro de Investigación PYSEIP.

## Líneas de Investigación

Principal interés es en el área de la inteligencia artificial, el internet de las cosas y las aplicaciones móviles.  
Líneas de investigación de cómputo y movilidad inteligente.

**CURRICULUM VITAE**  
**Dr. Sergio Valadez Godínez**

---

**GRADOS ACADÉMICOS**

- **2014-2018** Doctorado en Ciencias de la Computación, Instituto Politécnico Nacional
- 2010-2012 Maestría en Ciencias de la Computación, Instituto Tecnológico de León
- 1998-2003 Ingeniería en Sistemas Computacionales, Instituto Tecnológico de León



---

**DOCENCIA**

- **2025-actualidad** Jefe de Posgrado, UPIIZ-IPN
- **2024-2025** Profesor de Tiempo Completo, Universidad Tecnológica El Retoño, Aguascalientes
- **2024-actualidad** Docente Virtual de la Maestría en Inteligencia Artificial, Tecmilenio
- 2024 Profesor de asignatura Matemáticas y Física, Universidad Tecnológica de León
- 2021-2024 Profesor de Tiempo Completo Titular "A", Universidad Politécnica de Pénjamo
- 2021-2023 Docente Virtual de Maestría, Universidad Internacional de la Rioja (UNIR)
- **2019-actualidad** Profesor de asignatura por tiempo determinado, Universidad Humani Mundial
- 2020 Profesor de asignatura Matemáticas y Física, Universidad Tecnológica de León
- 2019-2020 Docente de Tiempo Completo de Ingenierías, Universidad Virtual del Estado de Guanajuato
- 2018 Profesor de Tiempo Completo Titular "A", Instituto Tecnológico Superior de Purísima del Rincón
- 2012-2013 Profesor Asociado "A", Instituto Tecnológico Superior de Irapuato Extensión Purísima del Rincón

---

**EXPERIENCIA EN INDUSTRIA Y COMERCIO**

- **2020-actualidad** Director general, Sr. Computadora, <https://srcomputadora.com.mx/>
- 2013 Gerente de sistemas, Jardín Alemán, S.A. de C.V., León, Gto.
- 2005-2010 Propietario y director general, SVG Computación, León, Gto.
- 2003-2005 Jefe de soporte técnico, Equipos de cómputo y oficina, León, Gto.
- 1998-2003 Jefe administrativo y de sistemas, Refaccionaria el Tornillo, San Francisco del Rincón, Gto.

---

**ARTÍCULOS CIENTÍFICOS PUBLICADOS**

- **2024** The Associative Pattern Classifier: Progress in theoretical understanding. *Journal of Intelligent & Fuzzy Systems*.
- 2022 Designing and Developing the First Version of A Spiking Neuron Simulator. *Research in Computing Science*.
- 2020 Novel mathematical model of breast cancer diagnostics using an associative pattern classification. *Diagnostics*.
- **2020** On the Accuracy and Computational Cost of Spiking Neuron Implementation. *Neural Networks*.
- 2017 How the Accuracy and Computational Cost of Spiking Neuron Simulation Are Affected by the Time Span and Firing Rate. *Computación y Sistemas*.
- 2017 The Step Size Impact on the Computational Cost of Spiking Neuron Simulation. *Computing Conference*.

- 2017 Efficient Pattern Recognition Using the Frequency Response of a Spiking Neuron. *Pattern Recognition*.
- 2015 Encoding Polysomnographic Signals into Spike Firing Rate for Sleep Staging. *Pattern Recognition*.
- 2015 A study of the associative pattern classifier method for multi-class processes. *Journal of Optoelectronics and Advanced Materials*.
- 2012 Clasificador Asociativo de Patrones Iterativo (CAPI). *Research in Computing Science*.

---

## PREMIOS, RECONOCIMIENTOS Y DISTINCIONES

---

**2025-2029 Investigador Nacional Nivel I SNII** • 2022 Miembro Consejo de Calidad Universidad Politécnica de Pénjamo • **2020 Candidato Investigador Nacional SNII** • 2018 PRODEP y miembro de cuerpos académicos Instituto Tecnológico Superior de Purísima del Rincón • **2013 Primer lugar Certamen Nacional de Tesis de Informática**

---

## IDIOMAS

---

- B2 de Inglés Linguaskill de Cambridge 2024
- Francés muy básico

---

## CONSIDERACIONES ACADÉMICAS Y TRAYECTORIA PROFESIONAL

---

**Creación de una nueva teoría de Redes Neuronales Artificiales (Cuarta Generación) dentro del marco del proyecto 65 de Fronteras de la Ciencia de CONAHCYT** • Asistencia a 5 congresos internacionales y 3 nacionales • Revisión de una propuesta para el programa de Ciencia Básica y de Frontera 2023-2024 del CONAHCYT • Participación en la evaluación de proyectos de investigación en 6 eventos nacionales • Revisión de 3 artículos de revistas internacionales, 17 artículos de congresos internacionales y 4 artículos de congresos nacionales • Participación en tres estancias de investigación nacionales • **Impartición de cerca de 60 cursos a nivel licenciatura y cerca de 11 a nivel maestría** • **Cerca de 50 cursos de formación, tanto presenciales como virtuales, en instituciones nacionales y extranjeras** (Instituto Tecnológico de Massachusetts, Universidad de Harvard, Berkeley, Universidad de California, École Polytechnique, Universidad Hebrea de Jerusalén, entre otras) • Miembro del consejo de calidad de la Universidad Politécnica de Pénjamo • Miembro del cuerpo académico de Ingeniería Informática del Instituto Tecnológico Superior de Purísima del Rincón • Obtención de 6 becas de estímulo institucional como estudiante por parte del IPN • **Más de diez años de experiencia en la industria privada implementado diversos tipos de sistemas de información** • **Emprendedor de negocios en el área de TICs.**

---

## CONSIDERACIONES DE INCIDENCIA Y BENEFICIO SOCIAL

---

**Graduación de 30 estudiantes mediante el asesoramiento de 16 tesis de licenciatura y 1 de maestría; así como 15 residencias profesionales a nivel de licenciatura** • **Mentor en el Genius Arena Hackaton de Talent Land México 2025** • **Mentor de proyectos de emprendimiento en el NASA International Space Apps Challenge desde el 2021 hasta hoy** • Medalla de plata en la XI edición del concurso estatal de proyectos de ciencia y tecnología, Expociencias Guanajuato 2023. Primer y segundo lugar en el hackathon de mejora regulatoria GTO 2023 del gobierno del estado de Guanajuato • Impartición de 11 conferencias de divulgación científica dirigidas al sector estudiantil • 2 entrevistas de divulgación para televisión • **2 talleres de divulgación para niños y adolescentes**